

**Universidad de El Salvador**  
**Facultad de Ciencias Naturales y Matemática**  
**Maestría en Estadística y Ciencia de Datos**  
**Inferencia Estadística y Regresión**

**Desarrollo de la tarea 2**

**Presentado por:** Salvador Enrique Rodríguez Hernández (rh06006)

**Fecha de entrega:** 04 de diciembre de 2024

1. *Estimar los parámetros  $\beta_0$  y  $\beta_1$  de un modelo de regresión lineal simple por el método de máxima verosimilitud y comparar los resultados obtenidos con el método de mínimos cuadrados.*

**Solución**

Estimación por Mínimos Cuadrados Ordinarios (OLS)

El método de mínimos cuadrados ordinarios (OLS) minimiza la suma de los errores cuadráticos:

$$SSE = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Para encontrar las estimaciones  $\widehat{\beta_0}$  y  $\widehat{\beta_1}$ , se deriva  $SSE$  respecto a  $\beta_0$  y  $\beta_1$  y se igualan a cero:

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \quad \dots\dots (1)$$

$$\frac{\partial SSE}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0 \dots\dots (2)$$

Resolviendo la ecuación (1):

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i$$

Dividiendo entre  $n$ :

$$\bar{y} = \beta_0 + \beta_1 \bar{x}$$

Así:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Despejando la ecuación (2) se tiene que:

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2$$

Usando  $\beta_0 = \bar{y} - \beta_1 \bar{x}$ :

$$\sum_{i=1}^n x_i y_i = (\bar{y} - \beta_1 \bar{x}) \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2$$

$$\sum_{i=1}^n x_i y_i = \bar{y} \sum_{i=1}^n x_i - \beta_1 \bar{x} \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2$$

$$\sum_{i=1}^n x_i y_i = \bar{y} \sum_{i=1}^n x_i + \beta_1 (\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i)$$

Despejando  $\beta_1$ :

$$\beta_1 = \frac{\sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i}$$

Multiplicando le numerador y denominador por  $\frac{1}{n}$ :

$$\beta_1 = \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{1}{n} \bar{y} \sum_{i=1}^n x_i}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n} \bar{x} \sum_{i=1}^n x_i}$$

$$\beta_1 = \frac{\frac{\sum_{i=1}^n x_i y_i}{n} - \bar{y} \bar{x}}{\frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2} \text{ o } \beta_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

Expresando el numerador como la covarianza y el denominador como la varianza se tiene:

$$\beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

Finalmente, se sustituye  $\beta_1$  en  $\beta_0 = \bar{y} - \beta_1 \bar{x}$ .

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_0 = \bar{y} - \left( \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} \right) \bar{x}$$

$$\beta_0 = \frac{\bar{y} (\sum_{i=1}^n x_i^2 - n \bar{x}^2) - \bar{x} (\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y})}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

$$\beta_0 = \frac{\bar{y} \sum_{i=1}^n x_i^2 - n \bar{x}^2 \bar{y} - \bar{x} \sum_{i=1}^n x_i y_i + n \bar{x}^2 \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

$$\beta_0 = \frac{\sum_{i=1}^n x_i^2 \bar{y} - \sum_{i=1}^n x_i y_i \bar{x}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

### Estimación por Máxima Verosimilitud (MLE)

Dado el modelo de regresión:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2)$$

La función de verosimilitud es:

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right)$$

Tomando el logaritmo natural se tiene que:

$$l(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}$$

Para maximizar  $l$ , se deriva respecto a  $\beta_0$ ,  $\beta_1$  y  $\sigma^2$ , y se iguala a cero:

Respecto a  $\beta_0$  y  $\beta_1$ :

$$\frac{\partial l}{\partial \beta_0} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial l}{\partial \beta_1} = \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Estas ecuaciones son equivalentes a las ecuaciones normales de OLS. Por lo tanto:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \beta_0 = \frac{\sum_{i=1}^n x_i^2 \bar{y} - \sum_{i=1}^n x_i y_i \bar{x}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

Respecto a  $\sigma^2$ :

$$\frac{\partial l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^4} = 0$$

Resolviendo para  $\sigma^2$ :

$$\widehat{\sigma^2} = \frac{\sum_{i=1}^n (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i)^2}{n}$$

#### Comparación entre OLS y MLE

- Ambos métodos proporcionan las mismas estimaciones para  $\beta_0$  y  $\beta_1$  bajo la suposición de normalidad en los residuos.
- MLE además estima  $\sigma^2$ , la varianza de los residuos, lo que no es calculado explícitamente por OLS.

2. En la regresión lineal múltiple, la idea es minimizar la suma de los cuadrados de los residuos ( $e$ ) definida como:

$$S(\beta) = \sum_{i=1}^n e_i^2 = e'e = (Y - X\beta)'(Y - X\beta)$$

Donde:

$Y$ : Vector de respuestas (variable dependiente).

$X$ : Matriz de diseño de las variables independientes.

$\beta$ : Vector de parámetros del modelo (coeficientes).

$e = Y - X\beta$ : Vector de residuos.

Al desarrollar  $S(\beta)$ :

$$S(\beta) = (Y - X\beta)'(Y - X\beta)$$

Usamos las propiedades del álgebra matricial para expandir el producto:

$$S(\beta) = Y'Y - \beta'X'Y - Y'X\beta + \beta'X'X\beta$$

Demostrar que  $-\beta'X'Y$  y  $-Y'X\beta$  son escalarmente equivalentes porque  $Y'X\beta$  es un escalar ( $1 \times 1$ ), y la transposición no afecta el valor escalar y, por lo tanto, podemos combinarlos:

$$S(\beta) = Y'Y - 2\beta'X'Y + \beta'X'X\beta$$

### Solución

Para justificar que  $-\beta'X'Y$  y  $-Y'X\beta$  son escalares y equivalentes, se comienza analizando sus dimensiones y propiedades fundamentales.

Dado que:

- $\beta$  es un vector columna de dimensión  $p \times 1$ ,
- $X$  es una matriz de diseño de dimensión  $n \times p$ ,
- $Y$  es un vector columna de dimensión  $n \times 1$ ,

se tiene que  $X'$  siendo la transpuesta de  $X$ , tiene dimensión  $p \times n$ . Al multiplicar  $X'$  por  $Y$ , el resultado es un vector columna de dimensión  $p \times 1$ . Posteriormente, al multiplicar este resultado por  $\beta'$ , que tiene dimensión  $1 \times p$ , se obtiene un escalar de dimensión  $1 \times 1$ . Por lo tanto, el término  $\beta'X'Y$  es un escalar.

De manera similar, en el término  $Y'X\beta$ , el vector  $Y'$ , siendo la transpuesta de  $Y$ , tiene dimensión  $1 \times n$ . Al multiplicarlo por  $X$  de dimensión  $n \times p$ , se genera un vector fila de dimensión  $1 \times p$ . Este vector fila, al multiplicarse por  $\beta$ , de dimensión  $p \times 1$ , produce nuevamente un escalar de dimensión  $1 \times 1$ . Por consiguiente,  $Y'X\beta$  también es un escalar.

Dado que  $\beta'X'Y$  es un escalar, su traspuesto es igual a sí mismo (el escalar es una matriz de  $1 \times 1$ ), es decir,  $\beta'X'Y = (\beta'X'Y)'$ , lo que implica que:

$$\begin{aligned}(\beta'X'Y)' &= (X'Y)'\beta \\ &= Y'X\beta\end{aligned}$$

En consecuencia, se tiene que:

$$\beta'X'Y = (\beta'X'Y)' = Y'X\beta$$

Es decir,  $\beta'X'Y$  y  $Y'X\beta$  son escalares equivalentes porque ambos representan el mismo valor. Esta equivalencia permite combinarlos directamente en la expansión cuadrática de  $e'e$ .

Sustituyendo la equivalencia escalar en la expansión original, se tiene que:

$$S(\beta) = Y'Y - 2\beta'X'Y + \beta'X'X$$